特征相关性对 Lasso 求解效率与稀疏恢复的影响

COMP6704 个人作业 · 中文研究报告草稿（第二版）
姓名：_____ 学号：_____
日期：2026 年 10 月 28 日（Asia/Shanghai）

摘要

本文把特征相关性、真实非零数量和支持布局共同作为实验因素，比较优化效率与稀疏恢复。新版固定噪声、单个信号幅度和三档绝对正则化，在 n=500、p=1000 下构造360个目标，由ISTA、FISTA、循环坐标下降与skglm求解，共1440次运行，其中1440次在预算内通过统一1e-6归一化对偶间隙。恢复评价覆盖误选、漏选、精确支持、符号与组支持，而不以非零数代替恢复质量。另用近期文献采用的UJIIndoorLoc与Leukemia完成72次真实设计比较。结果显示，求解成本与恢复效果应按相关性、稀疏度、布局及惩罚联合解释；达到同一目标精度不意味着不同数据上的真实支持同样容易恢复。

1 研究问题与近期研究定位

题目保持"特征相关性对Lasso求解效率与稀疏恢复的影响"。研究问题为：（1）固定噪声、系数幅度及惩罚时，相关性和真实非零数如何共同影响求解时间？（2）信号分散或集中在同组时，误选、漏选及符号恢复是否相同？（3）进一步缩小优化间隙能改善多少恢复效果？项目应用凸性、梯度步长、非光滑正则化、坐标最小化和对偶性，区别于小组的grokking神经网络优化器课题。

近期求解研究已关注正则化路径与模型选择[1]、排序稀疏惩罚的混合更新[2]、大规模变量筛选[3]和相关设计下的路径计时[4]。这些工作说明实际效率还受热启动、活跃集、罚项及预处理影响。本文保留三种基础方法解释机制，并增加skglm作为现代实现参照。

恢复方面，2025年的符号恢复设计研究强调效应方向和设计结构[5]；部分旋转设计理论区分不同列集合之间的几何[6]；平均情形研究还显式处理相关设计与污染[7]。skglm的软件基准[8]和2026年核心集研究[9]进一步提示应联合检查速度、目标质量与稀疏性。本文据此重设计实验，不宣称提出新算法或首次研究相关性。

2 近期文献的数据、内容与采用边界

表 1 2023年以来的核心研究及本项目取舍

工作与年份	论文的数据或设计	本项目采用的启发与边界
glmnet，2023[1]	模拟计时；Spambase分类	完整路径、热启动和模型选择，与独立单目标计时分开
SLOPE CD，2023[2]	相关合成；bcTCGA、news20、rcv1、Rhee2006	检查稀疏真值及多种误差；不把SLOPE算法当作普通Lasso CD
MI-Lasso，2024[3]	rat-eye 120×31098；超高维Eurostat	区分计算活跃集和真实支持；区分索引构建与求解成本，近似查询不套用严格safe保证
adelie，2024预印本[4]	相关高斯路径；Leukemia、UJIIndoorLoc、Prostate	采用其两套真实设计；主实验仍为独立目标，不声称复现完整路径
符号恢复设计，2025[5]	两水平超饱和设计，含已知/未知符号	增加支持布局和符号指标，不把条件性结果或猜想当作普遍保证
部分旋转，2025预印本[6]	半随机相关设计；主要为理论	记录活跃Gram及相对方向诊断；未施加论文的随机旋转
污染与相关设计，2025[7]	5列相关块，n1000、p1100，稀疏污染	借鉴分组和支持/符号控制；本轮不实现鲁棒增广目标
skglm，2025[8]	MEG/Lasso；癌症/Cox；药效/Group Lasso	实际加入安装版本0.5；库容差与后验统一精度分开
Lasso核心集，2026[9]	Synthetic、mediamill、CTs、mnist8m	真实设计配模拟响应；行抽样近似不同于完整目标的精度，不实现抽样

2.1 由文献落实到实验的改变

第一版只有一个真实非零数，且改变设计时同时按信号方差调节噪声、按λmax调节惩罚，难以单独解释恢复差异。第二版增加s=5/20/40和两种支持布局，固定σ=1与绝对λ；真实数据改为文献中的UJI回归和Leukemia高维设计。原版180次合成与Online News结果保留为初步实验，不混入本版统计。

每个固定目标共用数据、λ和零初始。skglm包含工作集与外推，提供当代软件背景；它的内部检查频率和停止量不同，不能将速度差全部归因于CD更新。文献中“筛选后留下多少计算变量”和“找回多少真信号”是不同问题，本实验分别记录。

3 模型、相关结构与稀疏恢复

$$\min_{w\in\mathbb{R}^p} P(w), \qquad P(w)=\frac{\|Xw-y\|_2^2}{2n}+\lambda\|w\|_1 \tag{1}$$

平方损失凸且光滑，ℓ 1项凸但在零点不可微；λ>0保证最优解存在。X和y按训练数据中心化，X按训练总体标准差缩放，验证/测试沿用参数，相当于保留未惩罚截距。合成真系数定义在该标准化坐标，取值±1。

$$x_{i,hj}^{\text{raw}}=\sqrt{\rho}\,z_{i,h}+\sqrt{1-\rho}\,e_{i,hj}, \quad y=Xw^\star+\varepsilon, \quad \varepsilon_i\sim\mathcal{N}(0,1) \tag{2}$$

组大小20，不同组独立；dispersed每个活跃组一个信号，clustered每个活跃组五个信号。相同种子跨ρ、s、布局共用设计分量、噪声实现与有序符号，同一布局的支持随s嵌套。固定σ和单个信号幅度保留了总信号能量及符号抵消的变化，SNR逐例记录。

$$\Sigma_b=(1-\rho)I+\rho\mathbf{1}\mathbf{1}^\top, \quad V_g=(1-\rho)k_g+\rho m_g^2 \tag{3}$$

k_g为组内真信号数，m_g为其符号和。上式是理想单位方差总体块的代数关系，不能替代训练标准化后的实测信号方差。混合符号可使高相关组内信号抵消；相同ρ并不代表相同恢复难度。

$$E_{\text{coef}}=\|w-w^\star\|_2/\|w^\star\|_2, \quad \widehat{S}_\tau=\{j:|w_j|>\tau\}, \quad \tau=10^{-6} \tag{4}$$

$$\text{Prec}=TP/(TP+FP), \quad \text{Rec}=TP/s, \quad F_1=2TP/(2TP+FP+FN), \quad \text{FDR}=FP/(TP+FP) \tag{5}$$

同时记录精确支持恢复、阈值后整个符号向量完全正确、真活跃符号正确率，以及组precision/recall/F1。空选择约定precision/recall/F1/FDR均为0，必须结合选择数解释。组支持允许同组替代，不能代替真实变量恢复；两布局的真组数量不同，也不能仅按组F1横向判优。五种子的精确恢复显示成功数/5，不作高精度概率估计。

$$I_S=\|G_{S^cS}G_{SS}^{-1}\text{sign}(w_S^\star)\|_\infty, \quad G=X^\top X/n \tag{6}$$

由于p>n且中心化，全Hessian奇异。采用真活跃Gram的最小特征值/条件数与样本I_S作为事后几何诊断，不作为算法先验，也不把I_S<1当作有限样本恢复保证。模型预测误差、系数误差、支持和符号指标各自回答不同问题。

4 求解方法、收敛与统一证书

$$\nabla f(w) = X^\top (Xw - y)/n, \quad L = \|X\|_2^2/n, \quad S_\tau(a) = \mathrm{sign}(a)\max(|a| - \tau, 0) \tag{7}$$

$$w_{\mathrm{ISTA}}^{k+1} = S_{\lambda/L}(w^k - \nabla f(w^k)/L) \tag{8}$$

软阈值是一维二次距离加绝对值惩罚的近端解。有效Lipschitz上界保证ISTA目标不增。FISTA在外推点z更新，t从1开始：

$$w^{k+1} = S_{\lambda/L}(z^k - \nabla f(z^k)/L), \quad t_{k+1} = (1 + \sqrt{1 + 4t_k^2})/2 \tag{9}$$

$$z^{k+1} = w^{k+1} + \frac{t_k - 1}{t_{k+1}}(w^{k+1} - w^k) \tag{10}$$

对具有最优解的凸复合目标，光滑项梯度Lipschitz连续、近端精确且步长有效时，ISTA/FISTA的经典目标残差上界分别为O(1/k)、O(1/k²)[10]。上界不等于实测对偶间隙的精确斜率，也不保证每个有限精度更快；本轮FISTA不重启。

$$a_j = \|X_j\|_2^2/n, \quad w_j^+ = S_\lambda(X_j^\top r/n + a_j w_j)/a_j, \quad r \leftarrow r - X_j(w_j^+ - w_j) \tag{11}$$

循环CD精确最小化每个一维子问题，并增量维护残差；完整遍历为一个epoch[11]。可分 $\ell 1$、光滑二次项、紧水平集和非零列的一维严格凸性质对应其收敛条件[12]，不宣称任意相关设计有统一线性常数。

表 2 方法与实际计算口径

方法	主更新/迭代口径	本轮实现
ISTA/FISTA	每步O(np)，额外O(n+p)	NumPy/BLAS；共同SVD步长
循环CD	每完整epoch O(np)	C99增量残差，无SVD
skglm	外层工作集轮数，不等于epoch	0.5版AndersonCD，工作集+外推

$$D(v) = (2y^\top v - \|v\|_2^2)/(2n), \quad r = y - Xw, \quad v = r/\max\{1, \|X^\top r\|_\infty/(n\lambda)\} \tag{12}$$

$$\|X^\top v\|_\infty \le n\lambda, \quad 0 \le P(w) - P^* \le P(w) - D(v), \quad \widetilde{G} = \frac{P - D}{\max(1, |P|, |D|)} \tag{13}$$

统一终点为归一化间隙 ≤ 1e-6。skglm本地KKT容差不等于该间隙，固定按1e-4/1e-6/1e-8从零重算直到后验合格，全部尝试累计计时；每次最多100个外层工作集轮，每子问题最多50000个内部epoch，最多拟合3次。只观察拟合端点，不混画密集精度轨迹。

5 实验协议与复现

表 3 新版合成实验因素

因素	冻结设置
规模	n500、p1000；独立测试n1000；组大小20
相关性/稀疏度	ρ=0/0.3/0.6/0.9；s=5/20/40
布局/符号	每活跃组1或5个信号；配对混合±1
噪声/惩罚	固定σ1；λ=cσ√(2log(p)/n)，c=0.5/1/2
重复/方法	5个配对种子；ISTA、FISTA、CD、skglm
主网格	4×3×2×3×5×4=1440次求解
计算/基本上限	float64，单线程，零初始；基本方法20秒、100000步

三档λ约0.08311/0.16623/0.33245，同一c跨所有结构使用相同绝对惩罚；λmax和λ/λmax仅记录。固定σ与系数幅度使噪声不再随s或符号抵消改变；总体SNR自然变化，所以结论应表述为固定单个信号、噪声与惩罚的结构效应。参考求解器在相同缩放下独立获得更高精度目标。

UJIIndoorLoc[13]使用官方19937条训练数据池，目标LONGITUDE，仅WAP001–520为输入。三个随机60/20/20划分为11962/3987/3988；先划分再删除训练常量/完全重复列并标准化，实际保留452/452/451列。全池删除55常量可得文献的465列，但本轮不使用全池预处理。100的未探测编码保留；位置、楼层、身份和时间字段不进入X。12点相对λ网格在验证集选最佳及邻近两点，四算法共36次；测试不调参。

Leukemia来自LIBSVM官方38+34条文件，合并72×7129并列标准化；二元标签编码后用于同一平方损失优化。三档相对λ、三次固定目标计时、四算法共36次，不报告泛化性能或真实支持恢复率。两数据均来自近期adelie普通Lasso实验；我们的划分、清洗和独立目标协议不等于论文的完整路径复现。

基本算法每5步/epoch检查，阈值时间为首次观察上界。计时含初始化和诊断，预测/阈值敏感性另记；近端SVD、数据准备、C/Numba首次编译分别记录。基本算法在更新间检查20秒，skglm只能在库拟合间/返回后检查，超额明确标记。未收敛不混作成功时间，恢复统计同时显示状态与成功子集。

32次代表性试跑全部收敛后冻结主网格；26项正确性测试通过，涵盖解析解、参考目标、证书、停止、配对和预处理。硬件Xeon Gold 6278C @2.60GHz，BLAS/OpenMP/Numba均1线程，Python3.13.13；NumPy2.5.1、SciPy1.18.0、skglm0.5。共享机器未独占，种子IQR是实例差异，非计时置信区间。

6 相关性与稀疏度对求解成本的共同影响

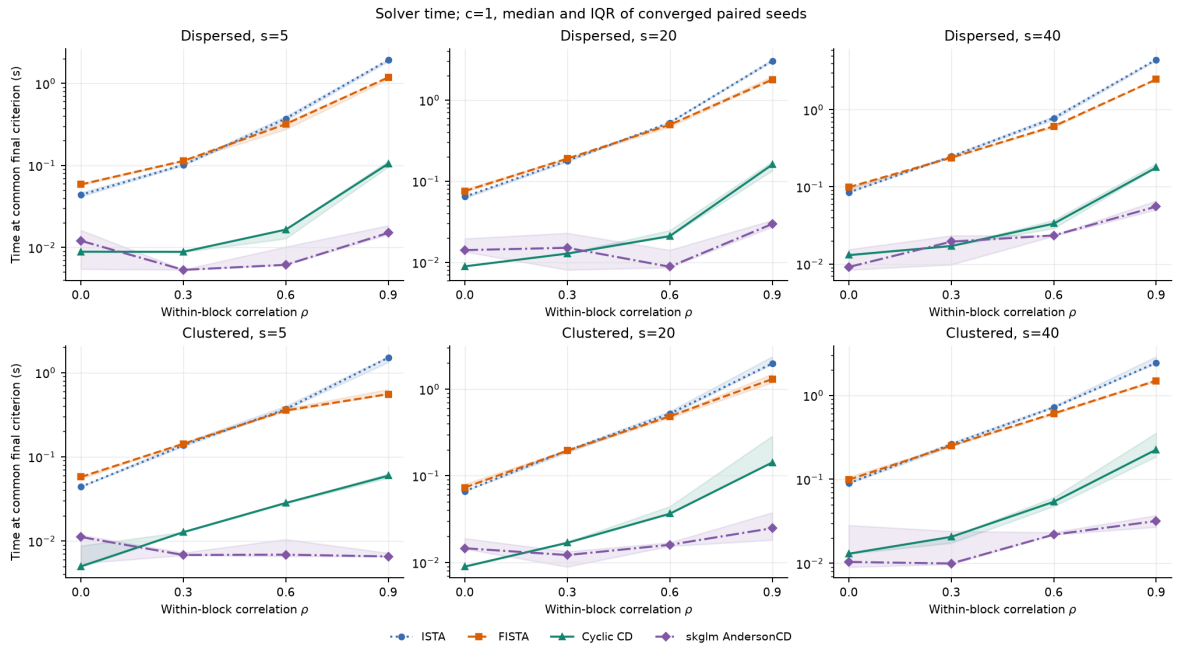


图1 c=1的求解时间；行区分布局、列区分s，五种子中位数与IQR。skglm只比较终点总调用时间。

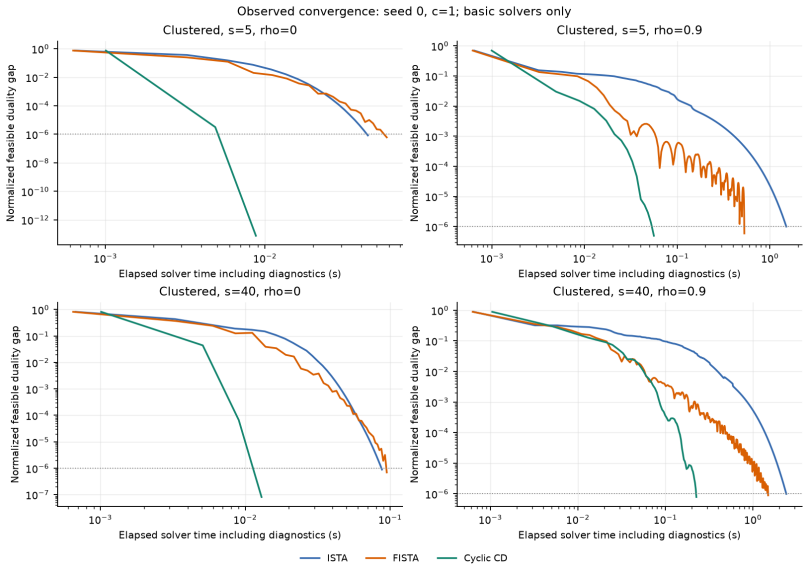


图2 种子0、clustered、c=1的代表轨迹，仅三种基本算法；迭代/epoch不等价。

在dispersed、s=40、c=1下，ρ=0→0.9时，ISTA中位耗时为0.085→4.459秒，FISTA为0.099→2.470，CD为0.013→0.178。这些是本设计与实现的条件性比较。

在相同ρ=0.9、dispersed、c=1时，s=5与40的CD中位耗时分别为0.105与0.178秒。现代基线含工作集、外推及容差重跑，迭代数不能与基本方法直接比较。更多信号改变活跃集和几何，仍须按布局与λ读图；加回SVD的独立启动图和全部未收敛计数另存，不只挑成功设置。

7 稀疏恢复：找对变量、符号与组

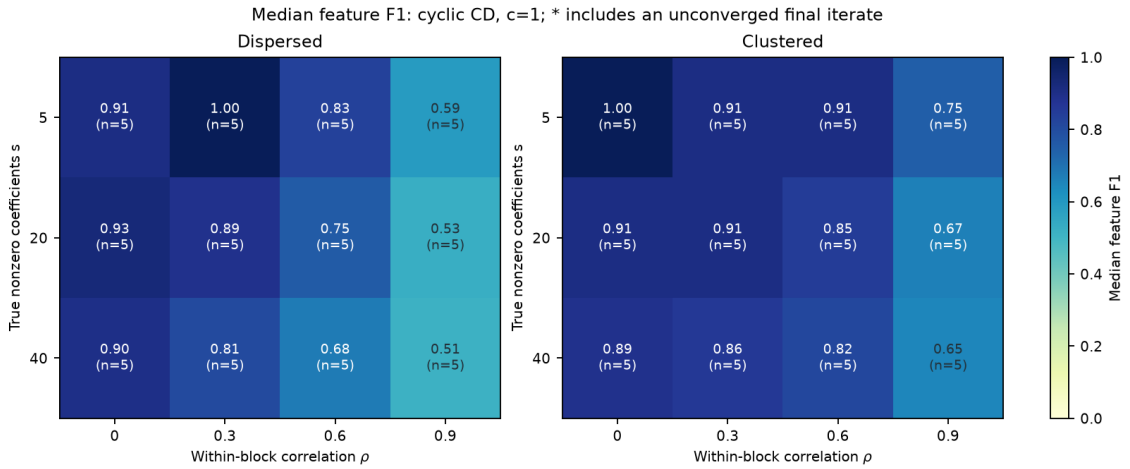


图3 c=1、CD的特征F1中位数，分别展示两布局下ρ×s交互；其余方法保留完整逐次记录。

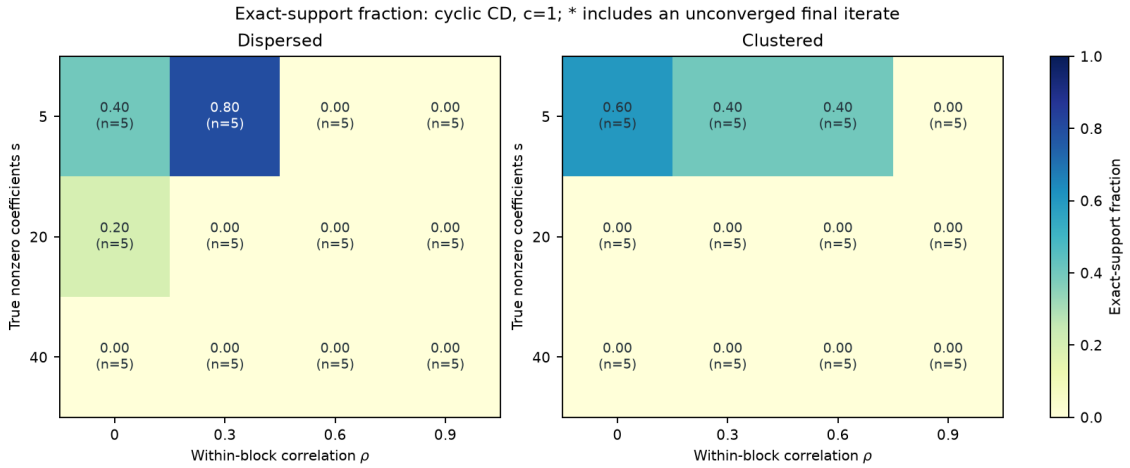


图4 CD、c=1的精确支持恢复比例；每格仅5个种子，等价于成功数/5，不是高精度总体概率。

dispersed、c=1、s=40的CD中位F1为ρ=0时0.899、ρ=0.9时0.513；高相关clustered同设置为0.649。同时，估计非零数分别为49、116、37，应结合precision=0.345与recall=1.000解释高相关分散设置，而非只看是否稀疏。

以CD、c=1为例，低相关分散s=5的精确支持成功2/5、完整符号成功2/5；高相关分散s=40分别为0/5和0/5。这些离散计数比F1更严格，不能由较高平均F1直接推断完全恢复。

在ρ=0.9、s=40时，两布局真活跃Gram条件数中位数分别为3.1与99.7，样本不可表示分数为1.29与2.27。不同诊断可朝不同方向变化；不能用某一个数单独解释恢复。

组内替代可使组F1高于特征F1，但两布局真组数为s与s/5，基准难度不同。“选择全部50组”在s40分散布局也会得到较高组F1。因此报告分别保留真组数、组选中数、误选/漏选与完整符号指标；不把预测接近等同于找到相同变量。

8 正则化、优化精度与恢复的区别

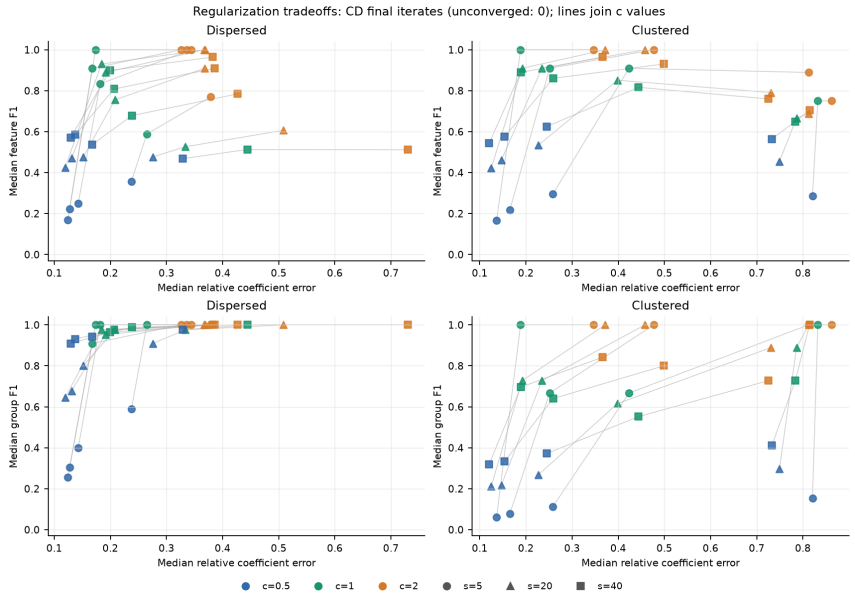


图5 CD终止解的五种子中位数；线连接相同ρ、s下三档c。系数误差、特征F1与组F1各有含义，不据测试结果挑阈值。

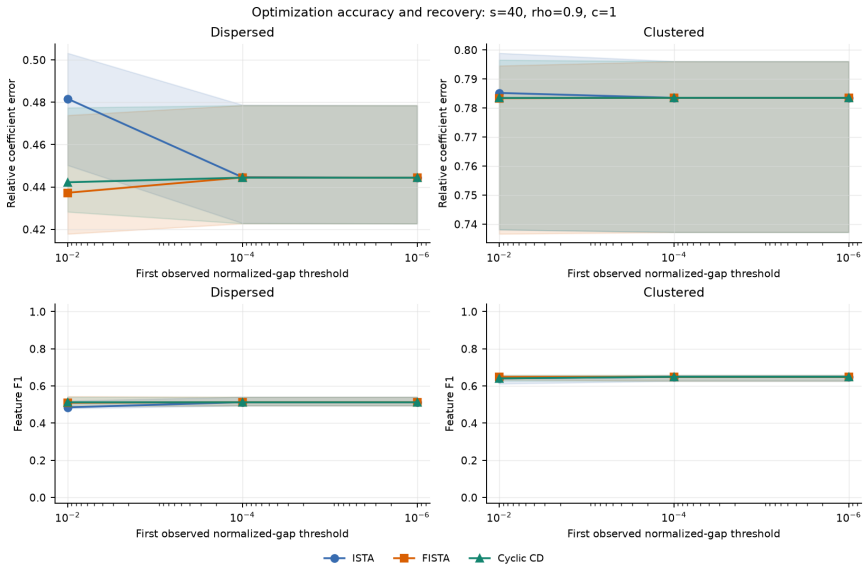


图6 s40、ρ0.9、c1，首次观测到三个间隙阈值时的系数与特征恢复；skglm无同等密度轨迹，未混入。

例如dispersed的ISTA首次达到1e-2/1e-4/1e-6时，中位系数误差为0.482/0.445/0.444。这些检查点相对于同一个λ目标；跨λ比较还包含正则化偏差，不能全部归因于求解精度。

支持阈值1e-8/1e-6/1e-4的数值敏感性中，108/1440次运行F1有变化，最大变化为0.0193。0.01/0.05是额外预定硬阈值，会改变估计支持，不作为Lasso原始支持或事后最优阈值。

9 真实设计验证、讨论与局限

表 4 UJI验证选择模型的跨划分结果

方法	UJI成功/3	终点测试MSE	终点非零数	成功求解秒
ISTA	0/3	922.16	334	未达标
FISTA	3/3	922.16	333	17.481
CD	3/3	922.16	333	3.350
skglm	3/3	922.16	332	1.393

上表按验证集最佳λ汇总中位数，MSE单位为原始经度坐标的平方。时间只汇总达标运行；MSE与非零数含20秒截断在内的所有终点，不据未达标预测比较同精度优劣。各档逐次记录在CSV，跨划分IQR在summary.json。随机留出不代表跨设备、时间外推或官方外部测试表现，真实支持未知。

表 5 Leukemia固定目标的三次计时中位数

方法	Leukemia λ/λmax=.01 秒	.1 秒	.3 秒
ISTA	未达标	未达标	未达标
FISTA	17.363	11.674	8.518
CD	1.010	0.142	0.110
skglm	0.106	0.039	0.031

Leukemia每个目标重复三次仅描述计时。新版各数据成功数为合成1440/1440、UJI27/36、Leukemia27/36。合成对参考目标的最大归一化差为1.42e-10；全部证书、原始gap、KKT、失败状态和配置签名可追溯。

9.1 结论与解释范围

相关性对求解和恢复的影响需要与真实非零数、支持布局、符号和惩罚共同分析。三个基本求解器主要改变达到给定目标精度的成本；统计恢复则还受目标偏差、噪声和设计几何限制。现代工作集/外推的性能优势属于整个实现，不能由本实验拆分为单一机制。

限制包括：每格仅五个种子；除Leukemia外没有逐实例多次计时；基本/库算法的内部诊断频率不同；全局SNR随信号数与符号抵消变化；组指标有真组占比差异；固定三档惩罚不是统计最优调参。真实数据不提供真支持。本轮没有实现全路径、筛选索引、SLOPE、核心集或鲁棒污染目标；这些文献用于设计和定位，不构成其复现。

参考文献

[1] Tay, J. Kenneth; Narasimhan, Balasubramanian; Hastie, Trevor. Elastic Net Regularization Paths for All Generalized Linear Models. Journal of Statistical Software, 2023, 106:1–31. 原文

[2] Larsson, Johan; Klopfenstein, Quentin; Massias, Mathurin; Wallin, Jonas. Coordinate Descent for SLOPE. Proceedings of the 26th International Conference on Artificial Intelligence and Statistics, 2023, 206:4802–4821. 原文

[3] Żogała-Siudem, Barbara; Jaroszewicz, Szymon. Variable screening for Lasso based on multidimensional indexing. Data Mining and Knowledge Discovery, 2024, 38:49–78. 原文

[4] Yang, James; Hastie, Trevor. A Fast and Scalable Pathwise-Solver for Group Lasso and Elastic Net Penalized Regression via Block-Coordinate Descent. arXiv:2405.08631（预印本）, 2024. 原文

[5] Stallrich, Jonathan W.; Young, Kade; Weese, Maria L.; Smucker, Byran J.; Edwards, David J.. An Optimal Design Framework for Lasso Sign Recovery. Journal of the Royal Statistical Society Series B: Statistical Methodology, 2025, 87:1457–1480. 原文

[6] Buhai, Rares-Darius. Lasso and Partially-Rotated Designs. arXiv:2505.11093（预印本）, 2025. 原文

[7] Minsker, Stanislav; Shen, Yiqiu. The Impact of Contamination and Correlated Design on the Lasso: An Average Case Analysis. Statistics & Probability Letters, 2025, 223:110417. 原文

[8] Moufad, Badr; Bannier, Pierre-Antoine; Bertrand, Quentin; Klopfenstein, Quentin; Massias, Mathurin. skglm: Improving scikit-learn for Regularized Generalized Linear Models. Journal of Machine Learning Research, 2025, 26:1–6. 原文

[9] Zou, Yuanbin; Huang, Junyu; Wang, Jianxin; Feng, Qilong. On Coreset for LASSO Regression Problem with Sensitivity Sampling. International Conference on Learning Representations, 2026. 原文

[10] Beck, Amir; Teboulle, Marc. A Fast Iterative Shrinkage-Thresholding Algorithm for Linear Inverse Problems. SIAM Journal on Imaging Sciences, 2009, 2:183–202. 原文

[11] Friedman, Jerome; Hastie, Trevor; Tibshirani, Robert. Regularization Paths for Generalized Linear Models via Coordinate Descent. Journal of Statistical Software, 2010, 33:1–22. 原文

[12] Tseng, Paul. Convergence of a Block Coordinate Descent Method for Nondifferentiable Minimization. Journal of Optimization Theory and Applications, 2001, 109:475–494. 原文

[13] Torres-Sospedra, J.; Montoliu, R.; Martínez-Usó, A.; Arnau, T.; Avariento, J.. UJIIndoorLoc. UCI Machine Learning Repository, 2014. 原文

代码获取与复现

随附comp6704_research_bundle_v2.zip提供源码、配置、逐次日志、系数、图表、数据下载及文献核查。主要入口为scripts/run_v2.py；scripts/analyze_v2.py从结果重建图表，scripts/build_report_v2.py重建本文。配置、哈希、依赖、26项测试、代表性重跑和资源记录见results/v2/verification.json及README。原始Leukemia文件不重新分发，按官方链接下载。最终对阅卷人可访问的代码位置待作者定稿补入。

姓名和学号按要求留空。报告正文先用中文，PDF不超过10页且小于20MB；课程截止为2026年11月29日23:59。本稿实现、运行和整理使用Codex辅助，仍需作者核验与提交。